BỘ CÔNG THƯƠNG · TRƯỜNG ĐẠI HỌC SAO ĐỎ · KHOA CÔNG NGHỆ THÔNG TIN

PHIẾU BÀI TẬP & HƯỚNG DẪN THỰC HÀNH

Bài tập thực hành PySpark: Phân tích nhật ký học tập & Cảnh báo học vụ

Học phần: Dữ liệu lớn - Big Data (0101103389) | **Số tín chỉ:** 3 TC
Giảng viên phụ trách: ThS. Lê Thị Hồng | **Phòng học:** B1-302 / B1-204 | **Học kỳ:** HK2 2025-2026

Tóm tắt học liệu: Bài tập thực hành phòng B1-204 viết pipeline PySpark phân tích 10 triệu bản ghi nhật ký LMS, Broadcast Join với danh mục học phần và xuất báo cáo Parquet phân vùng.

Phòng thực hành: B1-204 | Giảng viên: ThS. Lê Thị Hồng

BÀI TOÁN: Cho hai tập dữ liệu trên kho lưu trữ phân tán của cổng đào tạo số:

1. learning_events.parquet (~12 triệu dòng): (event_id, student_code, course_code, event_type, duration_sec, submitted_late, event_ts)
2. courses_catalog.csv (420 dòng): (course_code, course_name, faculty, credits)

YÊU CẦU CÀI ĐẶT PYSPARK:

Câu 1 (2.5 điểm) - Đọc dữ liệu với lược đồ tường minh (StructType), lọc bỏ bản ghi lỗi (student_code IS NULL hoặc duration_sec < 0) và chuẩn hóa cột ngày event_date = to_date(event_ts).

Câu 2 (2.5 điểm) - Thực hiện kết nối tối ưu giữa learning_events và courses_catalog bằng F.broadcast(courses_df); giải thích kế hoạch thực thi vật lý thông qua df.explain(True) (xác nhận xuất hiện BroadcastHashJoin thay vì SortMergeJoin).

Câu 3 (3.0 điểm) - Tính tổng số giờ tự học trực tuyến, tỷ lệ nộp bài trễ hạn của từng sinh viên theo từng khoa; dùng Window.partitionBy("faculty").orderBy(F.desc("total_hours")) để xếp hạng sinh viên và gắn nhãn cảnh báo sớm "CAN_HO_TRO" cho các sinh viên có thời lượng học < 2.0 giờ/ tuần và tỷ lệ trễ hạn > 40%.

Câu 4 (2.0 điểm) - Gộp phân vùng hợp lý bằng coalesce(4) và ghi kết quả ra định dạng nén Snappy Parquet phân vùng theo cột faculty (partitionBy("faculty")).